

RETAIL SALES FORECASTING AND RECOMMENDER — DARBA APRAKSTS

Tika izstrādāts pilns datu analīzes un mašīnmācīšanās risinājums, kas balstās uz tiešsaistes mazumtirgotāja gada transakciju datiem.

Risinājumam ir divas daļas:

- Nākamās dienas pārdošanas prognoze un produktu rekomendāciju sistēma. Prognozes daļā uz vienas un tās pašas laika rindas tika salīdzināti trīs modeļi — Random Forest, XGBoost un LSTM neironu tīkls.
- Rekomendāciju daļā tika analizēti atsevišķi klienti un izmantojot sadarbības filtrēšanu, sagatavoti produktu ieteikumi.

Dati tiek tīrīti ar konkrētu mērķi, nevis "vispārīgi". Prognozei un rekomendācijām no vieniem un tiem pašiem neapstrādātajiem datiem ir vajadzīgas atšķirīgas lietas, tāpēc tie tika tīrīti divos dažādos veidos. Prognozei svarīga ir tikai diena un naudas summa, tāpēc rindas bez klienta ID tika saglabātas; rekomendācijām klients ir būtisks, tāpēc šādas rindas tika atmetas.

Novērojumi

Datu kvalitāte. Sākotnējā datu apskate ar ``info()`` un ``describe()`` atklāja trīs problēmas: aptuveni ceturtajai daļai rindu nebija klienta ID, daži daudzumi bija negatīvi (atcelšanas un atgriešanas) un dažas cenas bija negatīvas (grāmatvedības labojumi). Šīs nebija kļūdas datos, bet fakti par tiem, un to apstrāde bija atkarīga no izmantošanas mērķa.

Piemēra koda pārskatīšana. Uzdevuma piemērs LSTM modelim datu mērogošanu izlaida, lai gan neironu tīkli ar lielām neapstrādātām vērtībām mācās nestabili — tā tika pievienota apzināti. Tāpat datumu kolonna jau bija pareizajā *datetime* tipā, tāpēc piemērā paredzētā datumu pārveidošana nebija vajadzīga.

Informācijas noplūdes novēršana. Tā kā runa ir par laika rindu, datu sadalījums treniņa un testa daļās tika veikts hronoloģiski (bez sajaukšanas). Sajaukšana ļautu modeļiem mācīties uz nākotnes dienām un radītu maldinošus labus rezultātus.

Modeļu salīdzinājums un secinājumi

Lai skaitļi būtu interpretējami, modeļi tika salīdzināti ar bāzes līniju (RMSE 30 373) — pieņēmumu, ka rītdienas ieņēmumi būs tādi paši kā šodien. Random Forest un XGBoost to pārspēj būtiski, savukārt LSTM bāzes līniju pārspēj minimāli, kas vēlreiz apstiprina, ka ar šādu datu apjomu dziļā mācīšanās priekšrocību nedod.

Vislabāk sevi parādīja Random Forest (RMSE 26 866), tam sekoja XGBoost (27 764), un vājākais LSTM (30 086). Dziļā mācīšanās nepārspēja klasiskos modeļus: ar tikai ~238 treniņa dienām neironu tīklam datu bija kritiski maz. Random Forest un XGBoost, kuru pamatā ir lēmumu koki, ar tik nelielu datu apjomu strādā labāk.

Abiem uz lēmumu kokiem balstītajiem modeļiem ir kopīgs ierobežojums: tie nespēj prognozēt vērtības, kas lielākas par treniņā redzētajām, tāpēc pirmssvētķu ieņēmumu pieaugumu tie novērtē par zemu.

Klientu analīzē atklājās, ka "vērtīgs klients" nav viens konkrēts tips: daži pērk bieži un mazos apjomos, citi reti, bet ļoti lielos apjomos. Šīm grupām nepieciešama atšķirīga pieeja.

Uz klientu līdzību balstīts rekomendētājs (collaborative filtering) iesaka produktus, ko pirkuši līdzīgi klienti un ko mērķa klients vēl nav iegādājies. Divi klienti ir līdzīgi, ja viņi pirkuši līdzīgus produktus, to nosaka ar kosinusa līdzību, salīdzinot katra klienta pirkumu vēsturi. Mērķa klientam sistēma iesaka produktus, ko pirkuši viņam līdzīgākie klienti un ko viņš pats vēl nav iegādājies. Jo līdzīgāks ir klients, jo vairāk viņa pirkumi ietekmē rekomendāciju.

Sistēmas noderīgums tika novērtēts ar $\text{hit-rate}@5$ — katram klientam tika paslēpta viena nopirktā produkta pozīcija un pārbaudīts, vai sistēma to ieteiktu starp šiem pieciem ieteikumiem. Rekomendētājs sasniedza 4,3% — aptuveni sešas reizes vairāk nekā populārāko produktu ieteikšana (0,7%), tātad personalizācija dod reālu efektu. Klientiem bez pirkumu vēstures sistēma atkāpjas uz populārākajiem produktiem, tāpēc tā vienmēr spēj sniegt ieteikumu.

Būtiskākais

Lielākā vērtība šajā darbā nav pati funkcionalitāte, bet metodiska pieeja un objektīvs novērtējums. Pareizā atbilde ne vienmēr ir sarežģītākais modelis — šeit vienkāršais Random Forest pārspēja gan XGBoost, gan LSTM. Svarīgāk par labāko rezultātu bija saprast, kāpēc tā notiek: par maz datu neironu tīklam, lēmumu koku nespēja iziet ārpus treniņa diapazona un informācijas noplūdes risks, ja sadalījums nebūtu hronoloģisks.